

**«Інтелектуальна підсистема класифікації відгуків на
товари українською мовою»**

АНОТАЦІЯ

У даній роботі розроблено інтелектуальну підсистему класифікації відгуків на товари українською мовою, яка дозволяє автоматизувати процес аналізу відгуків користувачів і визначення їх емоційного тону. Підсистема має на меті забезпечення ефективної обробки великої кількості текстових даних, що надходять від споживачів, для подальшого використання в аналізі споживчих уподобань і покращенні якості товарів та послуг. Особливістю розробленої системи є її здатність працювати з відгуками, написаними українською мовою, що дозволяє розширити можливості класифікації в контексті локальних ринків.

Основною метою роботи є розробка інтелектуальної підсистеми, здатної автоматично класифікувати текстові відгуки за категоріями, такими як позитивні, негативні та нейтральні. Це досягається за допомогою методів обробки природної мови, що дозволяють витягувати значущі ознаки з текстів, а також застосування алгоритмів машинного навчання для побудови моделей класифікації. Така підсистема є корисною для підприємств, оскільки надає можливість швидко оцінювати споживчі відгуки, виявляти тренди в сприйнятті товарів та послуг і здійснювати своєчасні коригування стратегії маркетингу або поліпшення продуктів.

Проект складається з пояснювальної записки, що включає наступні розділи – вступ, аналіз задачі та мотивацію, модель СШІ, експериментальне дослідження обраної моделі ШІ та зв'язок роботи з робототехнікою.

ЗМІСТ

ВСТУП.....	3
1. Загальна характеристика предметної області та розв'язуваних задач.....	4
1.1 Опис основного бізнес-процесу, який підлягає автоматизації.....	4
1.2 Мотивація та аналіз задачі.....	4
1.3 Постановка задачі.....	5
1.4 Формалізація задачі.....	6
2. Середовище розробки.....	8
2.1 Обране середовище розробки.....	8
3. Модель СШ.....	9
3.1. Вибір технології штучного інтелекту.....	9
3.2 Набір даних(датасет)	13
3.3Розробка моделі.....	13
3.3.1 Підготовка даних.....	13
3.3.2 Алгоритмічна реалізація моделі.....	16
3.3.3 Результати вирішення задачі.....	18
4. Експериментальне дослідження обраної моделі ШІ.....	20
4.1 Планування експерименту.....	20
4.2 Результати експерименту.....	21
ВИСНОВОК.....	28

ВСТУП

У сучасному інформаційному середовищі, де кількість даних, що генеруються щодня, зростає, важливою задачею для компаній є ефективне використання цих даних для покращення якості обслуговування клієнтів та вдосконалення товарів і послуг. Одним із ключових джерел такої інформації є відгуки користувачів, які зазвичай мають текстовий формат. Однак їх обробка вручну є трудомістким процесом, що обмежує оперативність прийняття рішень.

Автоматизація класифікації відгуків за емоційним тоном (позитивні, негативні, нейтральні) є важливим кроком для покращення цього процесу. Оскільки українська мова має специфічні граматичні та лексичні особливості, для її обробки необхідні спеціалізовані підходи, що ускладнює використання стандартних методів, розроблених для інших мов.

Метою цієї роботи є розробка інтелектуальної підсистеми класифікації відгуків на товари українською мовою, яка дозволить автоматично визначати емоційний тон тексту. Це дозволить оперативно оцінювати споживчі уподобання та коригувати стратегії компаній. У роботі розглянуто етапи збору та обробки даних, а також застосування методів машинного навчання для побудови ефективних моделей класифікації.

Розв'язувана проблема є важливою для бізнесу, оскільки дає змогу швидко реагувати на зміни у настроях споживачів і покращувати взаємодію з клієнтами, що підвищує конкурентоспроможність на ринку.

1. ЗАГАЛЬНА ХАРАКТЕРИСТИКА ПРЕДМЕТНОЇ ОБЛАСТІ ТА РОЗВ'ЯЗУВАНИХ ЗАДАЧ

1.1 Опис основного бізнес-процесу, який підлягає автоматизації

Основний бізнес-процес, що підлягає автоматизації, пов'язаний з обробкою відгуків споживачів на товари, розміщених на онлайн-платформах або вебсайтах компаній. Відгуки, що залишають користувачі, містять важливу інформацію про якість товарів, рівень обслуговування та сприйняття бренду. Однак зростаючий обсяг цих даних ускладнює їх ефективне оброблення вручну, що призводить до затримок у прийнятті рішень та недостатньої оперативності в реакціях на відгуки.

Автоматизація цього процесу дозволяє швидко класифікувати відгуки за емоційним тоном (позитивні, негативні, нейтральні), що допомагає підприємствам оперативно реагувати на проблеми, вдосконалювати свої товари та послуги, а також поліпшувати взаємодію з клієнтами. Ключова мета автоматизації – це побудова інтелектуальної системи, яка дозволить ефективно аналізувати великий потік текстових відгуків та визначати на їх основі значущу інформацію для бізнесу.

1.2 Мотивація та аналіз задачі

Задача класифікації відгуків є критично важливою для електронної комерції, оскільки відгуки користувачів часто впливають на рішення потенційних покупців. Однак обробка великої кількості таких відгуків вручну є надзвичайно трудомістким процесом, що затримує прийняття рішень і знижує ефективність бізнесу.

Автоматизація цього процесу за допомогою штучного інтелекту дає можливість швидко класифікувати відгуки за емоційним тоном (позитивні, нейтральні, негативні). Це допомагає підприємствам оперативно реагувати на проблеми, підвищувати лояльність клієнтів та використовувати позитивні відгуки у маркетингових кампаніях.

Основні переваги автоматичної класифікації:

- Швидка реакція на негативні відгуки для мінімізації незадоволених клієнтів.
- Використання позитивних відгуків у рекламі та підвищення іміджу бренду.
- Покращення взаємодії з клієнтами через персоналізовані рішення.

Задача має ряд особливостей, зокрема:

- Складність обробки природної мови: Відгуки можуть містити сарказм, емоційний підтекст, помилки в написанні, що ускладнює їх аналіз традиційними методами.
- Неоднозначність текстів: Відгуки часто містять змішані емоції, що потребує більш тонкого підходу до класифікації.
- Великі обсяги даних: Платформи електронної комерції щодня публікують тисячі відгуків, що потребує автоматизації процесу.

Таким чином, автоматизація процесу класифікації відгуків є ефективним та необхідним кроком для оптимізації бізнес-процесів і підвищення якості обслуговування клієнтів.

1.3 Постановка задачі

Метою даної роботи є розробка системи автоматичної класифікації відгуків користувачів електронної комерції за емоційним тоном за допомогою методів обробки природної мови та машинного навчання. Система повинна дозволяти швидко та ефективно визначати, чи є відгук позитивним, негативним або нейтральним, що допоможе підприємствам своєчасно реагувати на запити клієнтів, покращувати взаємодію з користувачами та оптимізувати маркетингові стратегії.

Основні завдання, які необхідно вирішити в рамках цієї роботи, включають:

1. Збір та попередня обробка даних: Зібрати достатньо великі та репрезентативні дані з відгуками користувачів, виконати їх очистку від шуму

(помилки у тексті, непотрібних символів), а також здійснити токенізацію та лематизацію для подальшого аналізу.

2. Розробка моделі класифікації: Створити та навчити модель машинного навчання для класифікації відгуків на основі їх емоційного тону. Для цього будуть застосовані різні методи, включаючи алгоритми на основі текстових ознак та нейронні мережі.

3. Оцінка ефективності моделі: Оцінити якість моделі за допомогою стандартних метрик класифікації, таких як точність, повнота, F1-міра, а також перевірити її здатність правильно класифікувати відгуки з різними стилями написання та емоційними відтінками.

Завдяки розв'язуванню цих завдань, система повинна забезпечити:

- Автоматичну класифікацію відгуків за емоційним тоном з високою точністю.
- Можливість масштабування для обробки великих обсягів даних.
- Підвищення ефективності реагування на клієнтські відгуки та покращення взаємодії з користувачами.

Рішення поставленої задачі допоможе підприємствам отримати інструмент для аналізу настроїв клієнтів, що в свою чергу сприятиме покращенню якості обслуговування та оптимізації бізнес-процесів.

1.4 Формалізація задачі

Формалізація задачі є важливим етапом у побудові системи, адже на цьому етапі чітко визначаються вхідні та вихідні параметри, зв'язки між ними, а також структура даних, яка буде використовуватися для навчання моделі.

Вхідні параметри:

1. Текст відгуку: Основним вхідним параметром є текстовий відгук клієнта. Це текстова інформація, яка характеризує ставлення користувача до певного товару чи послуги. Всі відгуки представлені на українській мові, що ускладнює задачу, оскільки необхідно враховувати граматичні та стилістичні особливості цієї мови.

2. Мітка класу: Кожен відгук має відповідну мітку, яка визначає його тональність. Мітки можуть набувати одного з трьох значень:

- "позитивний" – відгук виражає позитивне ставлення до товару;
- "нейтральний" – відгук не містить явної емоційної оцінки товару;
- "негативний" – відгук виражає негативне ставлення до товару.

Вихідні параметри:

1. Клас тональності: Клас тональності відгуку, що може бути одним із трьох значень: "позитивний", "нейтральний", "негативний". Це є результатом роботи моделі класифікації, яка призначає відповідну мітку класу до кожного відгуку.

Зв'язки між параметрами:

- Вхідний параметр текст відгуку після попередньої обробки (токенізація, векторизація) подається в модель машинного навчання, яка на основі аналізу тексту і тренувального набору даних передбачає результат — мітку класу.
- Для підготовки даних використовуються техніки попередньої обробки тексту, зокрема токенізація (перетворення тексту у набір числових представлень), векторизація та нормалізація. На основі цих перетворень можна отримати векторні уявлення відгуків, які використовуються для навчання моделі.

Датасет складається з текстів відгуків, позначених відповідними мітками класу. Формат зберігання даних — файл CSV, у якому кожен рядок містить текст відгуку та відповідну мітку класу. Дані організовуються у вигляді пари (відгук, мітка класу), що дозволяє навчати модель класифікації.

Для класифікації текстів на три категорії в процесі підготовки даних використовуються сучасні методи обробки текстів на основі трансформерів, зокрема BERT (Bidirectional Encoder Representations from Transformers). BERT дозволяє досягати високої точності завдяки двонаправленому кодуванню контексту в текстах, що покращує ефективність у порівнянні з класичними методами.

2. СЕРЕДОВИЩЕ РОЗРОБКИ

2.1 Обране середовище розробки

Для розробки проєкту обрано Visual Studio Code (VS Code) через його простоту у використанні, гнучкість налаштувань та широку підтримку розширень. Це середовище забезпечує ефективну інтеграцію з мовою програмування Python, яка була обрана основною завдяки її багатому екосистемі бібліотек для роботи з даними та машинним навчанням.

Python має численні інструменти для вирішення завдань обробки природної мови (NLP), серед яких:

1. TensorFlow — використовується для розробки та тренування моделей глибокого навчання.
2. Hugging Face Transformers — бібліотека для роботи з потужними трансформерними моделями, такими як BERT, RoBERTa, що дозволяє створювати високоточні моделі для класифікації текстів.
3. Sklearn — використовується для розділення набору даних, оцінки моделі та метрик, таких як точність і F1-метрика.
4. Matplotlib і Seaborn — для візуалізації результатів, таких як графіки точності і втрат, а також для побудови розподілу міток та словесних хмар.
5. Pandas — для обробки даних і роботи з таблицями.
6. NumPy — для роботи з масивами та числовими операціями.
7. WordCloud — для візуалізації частоти слів у вигляді хмари слів, що допомагає в аналізі текстів.
8. BeautifulSoup — для очищення HTML-контенту та видалення непотрібних тегів з тексту

Це середовище та інструменти дозволяють ефективно розробляти моделі для класифікації текстів, що можна використовувати в різноманітних застосунках, таких як аналіз відгуків, детекція емоцій у текстах тощо.

3. МОДЕЛЬ СШІ

3.1. Вибір технології штучного інтелекту

Для вирішення завдання класифікації відгуків на три категорії — негативні, нейтральні та позитивні — було обрано модель RoBERTa, а саме версію `TFRobertaForSequenceClassification` для задач класифікації текстів. Це одна з найпотужніших і найбільш застосовуваних технологій в обробці природної мови (NLP), що дозволяє отримувати високоточні результати.

Версія `TFRobertaForSequenceClassification` побудована на базі RoBERTa і зберігає основні принципи цієї архітектури, але додатково оснащена спеціальним шаром для класифікації, що дозволяє їй ефективно передбачати категорії тексту. Її здатність враховувати контекст як зліва, так і справа від кожного слова дозволяє точніше інтерпретувати значення слів у різних ситуаціях, що є критичним для правильної оцінки емоційного забарвлення тексту.

RoBERTa є вдосконаленою версією BERT, розробленою компанією Facebook AI, і є двосторонньою трансформерною моделлю, яка дозволяє ефективно враховувати контекст слів у повному тексті, що є особливо важливим для задачі класифікації відгуків, де контекст має критичне значення для правильної інтерпретації емоційного забарвлення тексту. Однією з основних відмінностей RoBERTa є те, що вона не використовує задачу передбачення наступного речення (Next Sentence Prediction, NSP), що дозволяє підвищити ефективність тренування. Також RoBERTa застосовує динамічне маскування та більші обсяги навчальних даних, що забезпечує кращу узагальнювальну здатність.

`TFRobertaForSequenceClassification` та RoBERTa мають спільну архітектуру, оскільки `TFRobertaForSequenceClassification` є адаптацією базової моделі RoBERTa для задач класифікації тексту. RoBERTa (Robustly Optimized BERT Approach) є загальною мовною моделлю, створеною для обробки тексту на основі трансформерної архітектури. Її основне призначення — це передбачення маскованих слів у тексті для кращого розуміння контексту. Вихід

RoBERTa — це набір контекстуальних векторів для кожного слова або токена у вхідному тексті, без специфічних шарів для класифікації. Ця модель використовується як основа для донавчання на конкретних задачах, таких як класифікація тексту, генерація або відповідь на запитання.

TFRobertaForSequenceClassification є спеціалізованою версією RoBERTa, розробленою для класифікації тексту. Ця модель вже має вбудований класифікаційний шар, який дозволяє передбачати ймовірності класів. Вона інтегрована з TensorFlow і використовує векторне представлення, отримане від базової моделі, для виконання прогнозів. Це робить її готовою до використання для класифікації текстів без необхідності додаткового налаштування архітектури.

Основна різниця між цими моделями полягає в їхньому призначенні та структурі. RoBERTa є загальною мовною моделлю, яка потребує адаптації для конкретних задач, тоді як TFRobertaForSequenceClassification є оптимізованим варіантом, спеціально призначеним для класифікації текстів.

Основні переваги RoBERTa:

1. Видалення цілі NSP: Модель не використовує задачу передбачення наступного речення, що дозволяє покращити ефективність при роботі з великими наборами даних.
2. Навчання на більших пакетах: Модель тренується на великих пакетах даних, що забезпечує кращу точність при виконанні задач класифікації тексту.
3. Динамічне маскування: Маскування слів під час навчання здійснюється динамічно, що підвищує здатність моделі до узагальнення.

RoBERTa є значним кроком уперед порівняно з BERT, завдяки вдосконаленій процедурі навчання, більшому набору даних і покращеним технікам, таким як динамічне маскування та використання більшого словника байтових пар. Вона досягла відмінних результатів у багатьох задачах NLP і має великий вплив на розвиток цієї галузі. Хоча модель вимагає великих ресурсів для навчання та налаштування, її ефективність робить її важливим інструментом для

дослідників та практиків у галузі обробки природної мови. Застосування цієї технології дозволить досягти високо якісних результатів у класифікації відгуків за емоційним забарвленням.

Як і інші трансформери, RoBERTa має обмеження:

1. Високі вимоги до ресурсів: Тренування та тонка настройка моделі потребують значних обчислювальних ресурсів.
2. Специфічність домену: Модель може вимагати додаткового навчання на даних специфічних для конкретного домену.
3. Інтерпретація результатів: Як і інші трансформери, модель є чорним ящиком, що ускладнює інтерпретацію її рішень, що може створювати проблеми в складних чи чутливих задачах.

Основні компоненти архітектури RoBERTa:

RoBERTa (Robustly Optimized BERT Approach) є покращеною версією BERT, яка базується на трансформерній архітектурі з механізмом самоуваги (self-attention). Ось основні аспекти її роботи:

1. Трансформерна архітектура: Включає багатошаровий кодувальник, що використовує механізм самоуваги для аналізу контексту слів та шар повнозв'язних нейронів для більш складних уявлень.
2. Механізм самоуваги: Кожне слово взаємодіє з усіма іншими словами у реченні для побудови контекстуальних уявлень, що дозволяє враховувати глобальний контекст.
3. Навчання: Модель тренується за допомогою маскування слів (Masked Language Model, MLM), де слова замінюються на спеціальний токен, і модель повинна передбачити їх. Динамічне маскування змінює масковані слова під час кожного етапу тренування.
4. Без NSP: Модель не використовує задачу прогнозування наступного речення (Next Sentence Prediction).
5. Більші дані і більші партії: Модель тренується на великих обсягах тексту та з більшими розмірами партій, що забезпечує високу точність.

6. Токенізатор: Використовується байтовий BPE токенізатор, що покращує обробку тексту на різних мовах.
7. Адаптація до завдання: Після тренування на великому корпусі тексту модель може бути донавчена (fine-tuned) на специфічні завдання, такі як класифікація тексту. Завдяки оптимізаціям та тренуванню на великих даних, RoBERTa демонструє кращі результати у порівнянні з BERT на різних завданнях NLP.

Додатковий шар в моделі `TFRobertaForSequenceClassification` відповідає за класифікацію тексту після того, як основна модель RoBERTa обробить вхідний текст. Основна модель RoBERTa генерує контекстуальні вектори для кожного слова або токена в тексті. Для класифікаційних задач важливий вихідний вектор спеціального токена, який репрезентує весь текст.

Цей вектор передається в додатковий шар, який складається з повнозв'язного (fully connected) нейронного шару. Цей шар має нейрони, що приймають рішення щодо того, до якого класу належить текст. Наприклад, для класифікації відгуків на категорії «позитивний», «нейтральний» або «негативний», шар генерує три значення — одне для кожного класу.

Після цього на виході застосовується функція активації, зазвичай Softmax, яка перетворює ці значення в ймовірності. Кожна ймовірність вказує, наскільки ймовірно, що текст належить до конкретного класу. Таким чином, додатковий шар перетворює контекстуальні вектори, отримані від RoBERTa, в конкретний прогноз для класифікації тексту.

Модель Roberta, а саме версія `TFRobertaForSequenceClassification` була обрана для класифікації відгуків через її високу ефективність в обробці текстів та здатність враховувати контекст на всьому текстовому рівні. Вона показує відмінні результати в класифікації завдяки трансформерній архітектурі RoBERTa, яка дозволяє точно інтерпретувати емоційне забарвлення тексту.

3.2 Набір даних(датасет)

Для реалізації системи класифікації відгуків про товари було створено власний набір даних, який містить 2100 текстових відгуків, що стосуються різних товарів. Датасет був зібраний з відкритих джерел в українському сегменті електронної комерції та включає в себе два основних стовпці: текст відгуку та мітку категорії, яка визначає тональність відгуку (позитивний, негативний або нейтральний). В таблиці 3.2.1 представлено розподілення набору даних на вибірки.

Таблиця 3.2.1 – Розподілення набору даних на вибірки

Навчальна вибірка (72%)	Валідаційна вибірка (8%)	Тестова вибірка (20%)
1512	168	420

3.3 Розробка моделі

3.3.1 Підготовка даних

Підготовка даних є важливим етапом при розробці моделі для класифікації текстових відгуків. На цьому етапі виконується кілька основних кроків:

1. Завантаження даних:

Дані про відгуки завантажуються з CSV файлу, який містить два стовпці: text (відгуки) та label (мітки категорій).

2. Попередня обробка тексту:

Текстові дані очищуються від небажаних елементів. За допомогою бібліотеки BeautifulSoup видаляються HTML-теги, а регулярними виразами видаляються спеціальні символи та зайві пробіли. В результаті ми отримуємо чисті текстові дані, готові до подальшої обробки.

```
def clean_text(text):
    soup = BeautifulSoup(text, "html.parser")
    text = re.sub(r'[[^]]*\]', '', soup.get_text())
    text = re.sub(r'^a-zA-Zа-яА-ЯёЁø-9\s', '', text)
    return text

df['cleaned_text'] = df['text'].apply(clean_text)
```

Рисунок 3.3.1.1 – Код для очищення тексту від зайвих символів

3. Кодування міток:

Категорії міток, що позначають тип відгуку (позитивний, нейтральний, негативний), перетворюються на числові значення. Це необхідно для того, щоб модель могла працювати з числовими мітками під час навчання. Для цього використовується словник, де кожній категорії відповідає своє число:

```
label_map = {'позитивний': 1, 'негативний': 0, 'нейтральний': 2}
df['label'] = df['label'].map(label_map)
```

Рисунок 3.3.1.2 – Код для кодування міток

4. Розподіл на вибірки:

Далі здійснюється поділ даних на навчальну, валідаційну та тестову вибірки. Це дозволяє ефективно тренувати модель, перевіряти її на валідаційних даних та оцінювати на тестових. Розподіл здійснюється за допомогою функції `train_test_split`, за допомогою цієї функції зберігаються пропорції кожної категорії у всіх підмножинах даних.

```
train_texts, test_texts, train_labels, test_labels = train_test_split(df['cleaned_text'],
                                                                    df['label'], test_size=0.2,
                                                                    stratify=df['label'])

train_texts, val_texts, train_labels, val_labels = train_test_split(train_texts,
                                                                    train_labels,
                                                                    test_size=0.1,
                                                                    stratify=train_labels)
```

Рисунок 3.3.1.3 – Код для розподілу даних на вибірки

На рисунку 3.3.1.4 представлений розподіл даних між трьома мітками класифікації відгуків: "позитивний", "нейтральний" та "негативний". Використано кругову діаграму для візуалізації відсоткового співвідношення між цими категоріями. Згідно з графіком, дані розподілені практично порівно. Такий розподіл є важливим для подальшого аналізу та тренування моделі.

2. Побудова моделі:

Для класифікації використовується модель Roberta, яка містить попередньо навчений трансформер, налаштований для задачі класифікації. Модель має три вихідні класи: позитивний, нейтральний і негативний. Вона навчається на підготовлених даних для класифікації текстів у ці категорії.

```
model = TFRobertaForSequenceClassification.from_pretrained("youscan/ukr-roberta-base",  
                                                         num_labels=3,  
                                                         from_pt=True)
```

Рисунок 3.3.2.2 – Код для побудови моделі

3. Навчання моделі:

Модель компілюється з використанням оптимізатора Adam, функції втрат SparseCategoricalCrossentropy та метрики точності. Після цього модель навчається на навчальних даних та валідується на валідаційних даних. Модель навчалася впродовж трьох епох – це оптимальна їхня кількість.

```
model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=2e-5),  
              loss=tf.keras.losses.SparseCategoricalCrossentropy(from_logits=True),  
              metrics=['accuracy'])  
  
history = model.fit(train_dataset.batch(8), validation_data=val_dataset.batch(8), epochs=3)
```

Рисунок 3.3.2.3 – Код для навчання моделі

4. Оцінка моделі:

Після навчання модель оцінюється на тестових даних. Для цього використовуються функції оцінки, що дозволяють отримати метрики точності та втрат.

```
test_loss, test_accuracy = model.evaluate(test_dataset.batch(8))  
print(f"Test Loss: {test_loss}")  
print(f"Test Accuracy: {test_accuracy}")
```

Рисунок 3.3.2.4 – Код для оцінки моделі

5. Прогнозування:

Після тренування модель використовується для прогнозування класів тестових відгуків. Це дозволяє оцінити ефективність моделі на невидимих раніше даних.

```
predictions = model.predict(test_dataset.batch(8))
predicted_classes = tf.argmax(predictions.logits, axis=-1)
```

Рисунок 3.3.2.4 – Код для прогнозування моделі

3.3.3 Результати вирішення задачі

Результати тестування моделі для задачі класифікації відгуків показують високі досягнення в усіх ключових метриках. Зокрема, модель продемонструвала низький рівень Loss, високу Accuracy та збалансовані показники Precision, Recall і F1-Score. Це свідчить про її ефективність у класифікації різних типів дій, що в свою чергу підтверджує здатність моделі добре справлятися з поставленою задачею, забезпечуючи точність і повноту класифікації. Нижче розглянемо детальніше ці результати та їх значення для оцінки ефективності моделі.

1. Значення Loss (0.2319) досить низьке, що вказує на хорошу здатність моделі до узгодження з реальними даними. Висока точність вказує на те, що модель добре мінімізує помилку при класифікації.
2. Тестова точність 94.29% є дуже хорошим результатом для задачі розпізнавання дій. Це вказує на те, що модель здатна правильно класифікувати більшість зразків, що свідчить про високу ефективність.
3. Precision (точність) для кожного класу варіюється від 0.9 до 0.99, що означає, що модель добре справляється з точністю класифікації для всіх класів.
4. Recall (повнота) для кожного класу варіюється від 0.94 до 0.95, що свідчить про високу здатність моделі знаходити всі відповідні зразки.
5. F1-Score (вимірює як точність, так і повноту) має високе значення, зокрема для кожного класу воно знаходиться в діапазоні 0.93–0.97, що є чудовим результатом.




Рисунок 3.3.3.1 – Графіки точності та втрат

```

Test Loss: 0.20877769589424133
Test Accuracy: 0.9476190209388733
      precision    recall  f1-score
0         0.90       0.95       0.93
1         0.99       0.95       0.97
2         0.95       0.94       0.95

F1 Score: 0.9479551711319021

```

Рисунок 3.3.3.2 – Оцінки за ключовими метриками

У результаті проведених аналізів моделі для задачі класифікації відгуків було здійснено детальне оцінювання її ефективності за допомогою основних метрик, таких як Loss, Accuracy, Precision, Recall та F1-Score. Отримані високі показники підтверджують високу точність та надійність моделі при класифікації різних типів дій. Зокрема, низький рівень Loss, висока точність і збалансовані значення Precision, Recall та F1-Score вказують на добре налаштовану модель, здатну до ефективної класифікації зразків. Проведений аналіз показує, що модель є потужним інструментом для виконання поставленого завдання, і її результати відповідають високим стандартам якості в обробці даних.

4. ЕКСПЕРИМЕНТАЛЬНЕ ДОСЛІДЖЕННЯ ОБРАНОЇ МОДЕЛІ ШІ

4.1 Планування експерименту

Для оцінки ефективності та продуктивності розробленої моделі RoBERTa, попередньо навченої на українському корпусі текстів, було проведено порівняння її результатів з іншими популярними підходами. Зокрема, аналізувалися наступні моделі:

1. BERT, попередньо навчена модель на стандартному англійському корпусі.
2. Класичний підхід із використанням мультиноміального наївного байєсівського класифікатора (MNB).

Основною метою аналізу було визначити, яка з моделей демонструє найкращі результати на різних підмножинах даних, зокрема на відгуках різної довжини (коротких, середніх та довгих).

Для моделі BERT, стандартно навченої на англійському корпусі, застосовувався той самий підхід, що і для розробленої моделі в цій роботі. Основною відмінністю було використання попередньо навченої моделі *bert-base-uncased*, яка працює з текстами англійською мовою. На рисунку 4.1.1 представлено код, що демонструє заміну моделі на базову. Три епохи для навчання це була оптимальна кількість епох для навчання.

```
tokenizer = BertTokenizer.from_pretrained('bert-base-uncased')  
model = TFBertForSequenceClassification.from_pretrained('bert-base-uncased', num_labels=3)
```

Рисунок 4.1.1 – Код заміни моделі на базову

Мультиноміальний наївний байєсівський класифікатор (MNB) — це статистичний метод машинного навчання, який базується на теоремі Байєса. Він широко використовується для задач класифікації текстів, особливо коли необхідно обробляти великі обсяги даних. Модель припускає, що кожна характеристика (слово чи термін) є незалежною від інших, що дозволяє ефективно обчислювати ймовірності належності тексту до певного класу. Завдяки простоті та швидкості, MNB часто застосовується як базова модель для порівняння з більш складними підходами. На рисунку 4.1.2 наведено код для

створення методу для векторизації тексту та створення моделі MNB і її навчання.

```
def vectorize_data(tr_text, ts_text):
    vectorizer = CountVectorizer()
    X_train_vec = vectorizer.fit_transform(tr_text)
    X_test_vec = vectorizer.transform(ts_text)

    return X_train_vec, X_test_vec, vectorizer

def train_naive_bayes(X_train_vec, y_train):
    mnb = MultinomialNB(alpha=0.1, fit_prior=True, force_alpha=True)
    mnb.fit(X_train_vec, y_train)

    return mnb
```

Рисунок 4.1.1 – Код для створення та навчання моделі MNB

4.2 Результати експерименту

Результати порівняння моделей за ключовими метриками подано в таблиці 4.2.1, а вплив довжини відгуків на продуктивність моделей проаналізовано в таблиці 4.2.2. Крім того, нижче представлено матриці плутанини для кожної моделі та для кожної множини відгуків(рис. 4.2.1, рис 4.2.2, рис. 4.2.3).

Таблиця 4.2.1 – Порівняння оцінок моделей

Назва моделі	Accuracy	Loss	Precision	Recall	F1-score	Час навчання (с)
RoBERTa (ua)	0.94	0.23	0.95	0.95	0.94	20.1 хв
BERT(en)	0.88	0.36	0.88	0.88	0.88	93.65 хв
MNB	0.98	0.08	0.98	0.98	0.98	0.03 с

Таблиця 4.2.2 – Порівняння впливу довжини відгуків на різні моделі

Назва моделі	Точність			Кількість неправильно-класифікованих відгуків
	Короткі відгуки (+-10 слів)	Середні відгуки (+-20 слів)	Великі відгуки (+-30 слів)	
RoBERTa (ua)	0.966	1.0	0.96	4
BERT (en)	0.9	0.93	0.9	16
MNB	0.95	0.98	0.93	8




Рисунок 4.2.1 – Матриці плутанини кожної моделі для множини відгуків малих розмірів




Рисунок 4.2.2 – Матриці плутанини кожної моделі для множини відгуків середніх розмірів




Рисунок 4.2.3 – Матриці плутанини кожної моделі для множини відгуків середніх розмірів

Аналіз результатів експерименту, представлених у таблицях 4.2.1 та 4.2.2, дозволяє зробити кілька важливих висновків щодо продуктивності моделей на основі ключових метрик та впливу довжини відгуків.

1. Порівняння моделей за ключовими метриками (Таблиця 4.2.1)

- **RoBERTa(ua):** Модель, яка була натренована на українських відгуках, показала дуже високі результати з Accuracy = 0.94, Precision = 0.95, Recall = 0.95, та F1-score = 0.94. Це свідчить про добре збалансовану модель з високою точністю виявлення позитивних результатів та низьким рівнем помилок. Важливою перевагою є також те, що час навчання цієї моделі становить 20.1 хвилин, що є порівняно швидким для такої складної моделі, як RoBERTa.
- **BERT(en):** Модель, натренована на англійськомовних відгуках, має нижчі показники продуктивності порівняно з BERT(ua). Зокрема, Accuracy = 0.88, Precision = 0.88, Recall = 0.88, та F1-score = 0.88. Це також

хороші результати, але показують певне зниження ефективності, що може бути пов'язано з більшими складнощами при обробці англomовних текстів у порівнянні з українськими. Час навчання цієї моделі є значно довшим, 93.65 хвилин, що вказує на вищі вимоги до ресурсів і часу.

- MNB: Модель на основі наївного баєсівського класифікатора (Naive Bayes) показала найкращий результат з Accuracy = 0.98, Precision = 0.98, Recall = 0.98, та F1-score = 0.98. Це свідчить про високу точність і здатність моделі правильно класифікувати більшість відгуків. Час навчання цієї моделі є дуже швидким – всього 0.03 с, що робить її найбільш ефективною з точки зору часу, але також може свідчити про її простоту та менш складні стратегії класифікації порівняно з BERT.

3. Вплив довжини відгуків на результати моделей (Таблиця 4.2.2)

- RoBERTa(ua): Модель, яка працює з короткими відгуками (приблизно 10 слів), показує хорошу точність 0.966. Для середніх відгуків (20 слів) результат ідеальний – 1.0, що може вказувати на дуже високу здатність моделі аналізувати середні за довжиною тексти. Проте для великих відгуків (30 слів) точність знову знижується до 0.96, що свідчить про деякі труднощі при обробці довших текстів.
- BERT(en): Для цієї моделі результати менш стабільні. Для коротких відгуків точність складає 0.9, для середніх 0.93, але для великих відгуків точність знову знижується до 0.9. Це свідчить про певні труднощі з аналізом довших текстів, що може бути наслідком не тільки мовних, а й контекстуальних проблем при роботі з англomовними відгуками.
- MNB: Модель наївного баєсівського класифікатора демонструє стабільні результати, з 0.95 для коротких відгуків, 0.98 для середніх і 0.93 для великих відгуків. Хоча вона показує зниження точності для

довших текстів, її результат для середніх відгуків є найкращим серед усіх моделей, що вказує на оптимальну здатність обробляти текст середньої довжини.

RoBERTa(ua) є дуже ефективною моделлю для аналізу українських відгуків, з високими результатами за всіма метриками. Однак її продуктивність дещо знижується для великих відгуків, що може вимагати подальшої оптимізації або використання іншої стратегії обробки довгих текстів.

BERT(en) має трохи гірші показники, зокрема для великих відгуків, що вказує на деякі проблеми при обробці англomовних текстів, ймовірно, через складніший лінгвістичний контекст.

MNB демонструє стабільну і високу продуктивність при обробці текстів середньої довжини, хоча її точність трохи знижується при роботі з великими відгуками.

Крім того найменше помилок допустила модель RoBERTa (ua), а модель MNB найчастіше робила помилки під час класифікації.

Загалом, для різних довжин відгуків, вибір моделі залежить від специфічних вимог завдання: якщо потрібна висока точність для коротких і середніх відгуків, MNB є оптимальним варіантом. Для більш складних задач і потреби в точному аналізі великих текстів RoBERTa(ua) є кращим вибором, хоча для ще кращого результату є необхідність невеликої оптимізації.

ВИСНОВОК

У даній роботі на тему "Інтелектуальна підсистема класифікації відгуків на товари українською мовою" була розроблена модель RoBERTa, що була переднавчена на великих обсягах текстів українською мовою для класифікації відгуків. Цей підхід дозволяє досягти значних покращень в обробці та аналізі текстів на рідних мовах користувачів, що є важливим аспектом для багатьох застосувань, включаючи робототехніку, обслуговування клієнтів та аналіз зворотного зв'язку.

Після навчання моделі RoBERTa, вона була порівняна з двома іншими моделями: BERT(en), яка була переднавчена на англomовних текстах, і MNB (Multinomial Naive Bayes), яка є традиційною моделлю для класифікації текстів.

Розроблена модель RoBERTa показала значні переваги при роботі з українськими текстами, продемонструвавши високу точність, точність класифікації та здатність ефективно працювати з різними довжинами текстів. Це підкреслює важливість адаптації моделей до специфічних мовних особливостей, таких як морфологія та синтаксис української мови.

З огляду на отримані результати, можна зробити висновок, що переднавчена модель RoBERTa, адаптована для української мови, є потужним інструментом для класифікації текстів, що дозволяє досягати високої точності при роботі з відгуками українською мовою. Однак для використання в реальних системах на основі специфічних вимог до швидкості обробки та обсягів даних, можуть бути корисними й інші моделі, такі як MNB, які є більш ресурсозберігаючими.

Для покращення моделі класифікації відгуків можна застосувати кілька підходів. Розширення навчальної вибірки дозволить моделі краще адаптуватися до різних варіантів відгуків. Фінетюнінг на специфічних даних покращить контекстуальне розуміння. Заміна токенізаторів та використання суб-слова токенізації допоможуть зберегти значення слів. Використання потужніших моделей, як RoBERTa-large або XLM-RoBERTa, підвищить точність. Для детальнішої оцінки можна застосувати додаткові метрики. Балансування класів

та методи регуляризації, такі як dropout, знизять ризик перенавчання. Оптимізація гіперпараметрів та покращення попередньої обробки тексту також сприятимуть покращенню результатів. Додавання додаткових ознак, таких як довжина відгуку чи частота емодзі, допоможе підвищити точність класифікації.

Це дослідження підкреслює важливість розвитку та використання адаптованих мовних моделей для різних мовних середовищ, що є критичним для автоматизації процесів обробки текстів і поліпшення взаємодії з користувачами різних сферах.

